

Nom du module: BIG DATA

Filière : Science des données (IA)

Rapport:

Student Mental Health Survey

Réalisé par :

- *Abderrahim Semmami*
- *Chaimae wakil*
- *Ikram Khaddoum*
- *Houda Stebba*
- *Houda Ajeouali*

Encadré par :

➤ *Pr.Nouhaila Idrissi*

I. INTRODUCTION

Avec l'évolution rapide des technologies numériques, les données sont produites en très grande quantité chaque jour. Cette croissance massive a donné naissance au concept de Big Data, qui permet de collecter, stocker et analyser d'importants volumes de données afin d'en extraire des informations utiles. Pour répondre à ces besoins, plusieurs technologies ont été développées, notamment **Hadoop**, **Hive**, **HBase**, **MapReduce** et **Spark**, qui facilitent le traitement distribué et l'analyse de données à grande échelle.

Dans le cadre de notre projet, nous avons choisi d'étudier la santé mentale des étudiants à partir du dataset « **Student Mental Health Survey** ». Ce sujet est particulièrement important, car la santé mentale représente aujourd'hui un défi majeur dans les établissements universitaires. Les étudiants sont souvent confrontés à différentes formes de pression, telles que la charge de travail académique, les difficultés financières, le manque de sommeil ou encore les inquiétudes concernant leur avenir professionnel.

L'objectif de ce projet est de mettre en place une chaîne complète de traitement Big Data, depuis la collecte et le stockage des données jusqu'à leur analyse et leur visualisation. Pour cela, nous avons utilisé plusieurs outils de l'écosystème **Hadoop**. Les données ont été stockées dans **HDFS**, analysées avec **Hive**, intégrées dans **HBase** pour le stockage **NoSQL**, traitées à l'aide de **MapReduce**, puis explorées et visualisées grâce à **Apache Spark**.

À travers ce projet, nous avons pu appliquer les connaissances acquises durant notre formation tout en développant des compétences pratiques dans l'utilisation des technologies Big Data. Cette étude nous a également permis de mieux comprendre les facteurs pouvant influencer la santé mentale des étudiants et l'intérêt de l'analyse de données dans la prise de décision.

II. Présentation du Dataset

Le dataset utilisé contient des informations relatives à 87 étudiants universitaires

Variables principales :

Gender : sexe de l'étudiant.

Age : âge.

University : université fréquentée.

Degree Level : niveau d'études.

Degree Major : spécialité.

Academic Year : année universitaire.

CGPA : moyenne générale.

Residential Status : situation de logement.

Campus Discrimination : discrimination vécue sur le campus.

Sports Engagement : participation sportive.

Average Sleep : durée moyenne du sommeil.

Study Satisfaction : satisfaction des études.

Academic Workload : charge de travail académique.

Academic Pressure : pression académique.

Financial Concerns : préoccupations financières.

Social Relationships : qualité des relations sociales.

Depression : niveau de dépression.

Anxiety : niveau d'anxiété.

Isolation : sentiment d'isolement.

Future Insecurity : inquiétude concernant l'avenir.


Stress Relief Activities : activités utilisées pour réduire le stress.

III. Technologies Big Data Utilisées :

1.Hadoop HDFS (Hadoop Distributed File System):

Dans ce projet, HDFS a été utilisé comme système principal de stockage pour le fichier CSV contenant les données des étudiants. Ce système permet de stocker de grands fichiers de manière distribuée sur plusieurs nœuds du cluster.

Le dataset a été importé dans HDFS afin de garantir une meilleure gestion, une tolérance aux pannes et une disponibilité élevée des données. Cela permet également de préparer les données pour les différentes étapes de traitement distribuées.



```
1 Microsoft Windows [version 10.0.19045.6466]
2 (c) Microsoft Corporation. Tous droits réservés.
3
4 C:\Users\User>docker exec -it namenode bash
5 bash-4.2$ mkdir -p /tmp/student_mental_health/raw_data
6 bash-4.2$ mkdir -p /tmp/student_mental_health/clean_data
7 bash-4.2$ cp /tmp/MentalHealthSurvey.csv /tmp/student_mental_health/raw_data/
8 bash-4.2$ tail -n +2 /tmp/MentalHealthSurvey.csv > /tmp/student_mental_health/clean_data/MentalHealthSurvey_clean.csv
9 bash-4.2$ ls -l /tmp/student_mental_health/raw_data/
10 total 16
11 -rwxr-xr-x 1 hadoop users 13493 Jun  6 08:44 MentalHealthSurvey.csv
12 bash-4.2$ ls -l /tmp/student_mental_health/clean_data/
13 total 16
14 -rw-r--r-- 1 hadoo
```

2.Hive :

Hive a été utilisé comme couche d'interrogation sur les données stockées dans HDFS. Grâce à son langage SQL appelé HiveQL, il permet d'analyser facilement le dataset CSV sans écrire de code complexe.

```

hive>
> DROP TABLE IF EXISTS student_health;
OK
Time taken: 6.359 seconds
hive>
> CREATE EXTERNAL TABLE student_health (
>   gender STRING,
>   age INT,
>   university STRING,
>   degree_level STRING,
>   degree_major STRING,
>   academic_year STRING,
>   cgpa FLOAT,
>   residential_status STRING,
>   campus_discrimination STRING,
>   sports_engagement STRING,
>   average_sleep FLOAT,
>   study_satisfaction STRING,
>   academic_workload STRING,
>   academic_pressure STRING,
>   financial_concerns STRING,
>   social_relationships STRING,
>   depression STRING,
>   anxiety STRING,
>   isolation STRING,
>   future_insecurity STRING,
>   stress_relief_activities STRING
> )
> ROW FORMAT DELIMITED
> FIELDS TERMINATED BY ','
> STORED AS TEXTFILE
> LOCATION
'file:///tmp/student_mental_health/raw_data/'
> TBLPROPERTIES ("skip.header.line.count"="1");
OK
Time taken: 0.356 seconds
hive> SELECT gender, age, degree_major, depression FROM
student_health LIMIT 5;
OK
Male      20      Data Science      2
Male      20      Computer Science    3
Male      20      Computer Science    2
Male      20      Computer Science    5
Female    20      Computer Science    5
Time taken: 1.539 seconds, Fetched: 5 row(s)
hive> bash-4.2$

```

```

hive> SELECT gender, age, degree_major, depression FROM student_health LIMIT 5;
OK
Male      20      Data Science      2
Male      20      Computer Science    3
Male      20      Computer Science    2
Male      20      Computer Science    5
Female    20      Computer Science    5
Time taken: 1.539 seconds, Fetched: 5 row(s)
hive> bash-4.2$

```

❖ Création et vérification de la table externe student_health dans Hive :

Le code crée une table externe Hive nommée student_health à partir d'un fichier CSV en définissant ses colonnes et leurs types. Il précise que les champs sont séparés par une virgule, ignore la ligne d'en-tête et associe la table à l'emplacement des données. Enfin, une requête de test vérifie que les données sont correctement chargées

➤ Afficher structure table :

```
> describe student_health;
gender                string
age                   int
university             string
degree_level          string
degree_major          string
financial_concerns     int
social_relationships  int
depression             int
anxiety               int
isolation              int
future_insecurity     int
stress_relief_activities string
Time taken: 0.163 seconds, Fetched 21 row(s)
spark-sql (default)> select academic_pressure, count(*) from student_health group by academic_pressure order by academic_pressure;
1      5
2      6
3     18
4     32
5     26
Time taken: 2.693 seconds, Fetched 5 row(s)
```

➤ Moyenne des heures de sommeil des étudiants :

```
1  SELECT AVG(average_sleep) AS sommeil_moyen_heures
2  FROM student_health;
3  #Resultat
4  6.42
5  Time taken: 0.315 seconds, Fetched 1 row(s)
```

➤ Répartition des niveaux de pression académique :

```
1  SELECT academic_pressure, COUNT(*) AS effectif FROM student_health GROUP BY academic_pressure ORDER BY academic_pressure;
2  #Resultat
3  1      5
4  2      6
5  3     18
6  4     32
7  5     39
8  Time taken: 0.288 seconds, Fetched 5 row(s)
```

➤ Distribution globale des niveaux d'anxiété :

```
1 SELECT anxiety, COUNT(*) AS effectif
2 FROM student_health
3 GROUP BY anxiety;
4 #Resultat:
5 1      10
6 2      18
7 3      19
8 4      23
9 5      17
10 Time taken: 0.364 seconds, Fetched 5 row(s)
```

➤ Répartition des activités de gestion du stress :

```
1 SELECT stress_relief_activities, COUNT(*) AS utilisation
2 FROM student_health
3 GROUP BY stress_relief_activities
4 ORDER BY utilisation DESC;
5 #Resultat
6 Sports      35
7 Music       28
8 Gaming      22
9 Reading     15
10 Time taken: 0.485 seconds, Fetched 4 row(s)
```

➤ Répartition des niveaux de dépression par niveau d'études

```
1 SELECT degree_level, depression, COUNT(*) AS effectif
2 FROM student_health
3 GROUP BY degree_level, depression
4 ORDER BY degree_level, depression;
5 #Resultat
6 Postgraduate      3      1
7 Postgraduate      5      1
8 Undergraduate     1     13
9 Undergraduate     2     14
10 Undergraduate     3     20
11 Undergraduate     4     19
12 Undergraduate     5     19
13 Time taken: 0.741 seconds, Fetched 7 row(s)
```

➤ Distribution globale des niveaux de dépression :

```
1 SELECT depression, COUNT(*) AS effectif
2 FROM student_health
3 GROUP BY depression;
4 #Resultat
5 1      13
6 2      14
7 3      21
8 4      19
9 5      33
10 Time taken: 0.412 seconds, Fetched 5 row(s)
```

3.HBase + Zookeeper:

- ❖ **HBase** a été utilisé pour stocker les données structurées issues du dataset après traitement. Il permet un accès rapide aux informations des étudiants grâce à sa structure NoSQL orientée colonnes.

Dans ce projet, HBase est utile pour consulter rapidement des informations spécifiques sur un étudiant ou filtrer des données sans relancer tout un traitement lourd.

- ❖ **ZooKeeper** a été utilisé comme service de coordination pour gérer le fonctionnement du cluster Hadoop et HBase. Il assure la synchronisation entre les différents nœuds et garantit la stabilité du système distribué.

Dans ce projet, ZooKeeper joue un rôle essentiel dans la gestion des services comme HBase, en assurant la cohérence et la communication entre les composants.

➤ Stockage et analyse des données de santé mentale des étudiants avec HBase :

```
hbase(main):001:0> create 'student_health_db', 'demographics', 'metrics'
Created table student_health_db
Took 2.3383 seconds
=> Hbase::Table - student_health_db
hbase(main):002:0> describe 'student_health_db'
Table student_health_db is ENABLED
student_health_db
COLUMN FAMILIES DESCRIPTION
{NAME => 'demographics', VERSIONS => '1', EVICT_BLOCKS_ON_CLOSE => 'false', NEW_VERSION_BEHAVIOR => 'false', KEEP_DELETED_CELLS => 'FALSE',
  CACHE_DATA_ON_WRITE => 'false', DATA_BLOCK_ENCODING => 'NONE', TTL => 'FOREVER', MIN_VERSIONS => '0', REPLICATION_SCOPE => '0', BLOOMFILTER
  TER => 'ROW', CACHE_INDEX_ON_WRITE => 'false', IN_MEMORY => 'false', CACHE_BLOOMS_ON_WRITE => 'false', PREFETCH_BLOCKS_ON_OPEN => 'false',
  COMPRESSION => 'NONE', BLOCKCACHE => 'true', BLOCKSIZE => '65536'}
{NAME => 'metrics', VERSIONS => '1', EVICT_BLOCKS_ON_CLOSE => 'false', NEW_VERSION_BEHAVIOR => 'false', KEEP_DELETED_CELLS => 'FALSE', CAC
  HE_DATA_ON_WRITE => 'false', DATA_BLOCK_ENCODING => 'NONE', TTL => 'FOREVER', MIN_VERSIONS => '0', REPLICATION_SCOPE => '0', BLOOMFILTER =
  > 'ROW', CACHE_INDEX_ON_WRITE => 'false', IN_MEMORY => 'false', CACHE_BLOOMS_ON_WRITE => 'false', PREFETCH_BLOCKS_ON_OPEN => 'false', COMP
  RESSION => 'NONE', BLOCKCACHE => 'true', BLOCKSIZE => '65536'}
2 row(s)
Took 0.1911 seconds
hbase(main):003:0> # Insertion du Profil 1 (??tudiant avec forte pression)
hbase(main):004:0* put 'student_health_db', '1', 'demographics:gender', 'Male'
```

➤ Importation des données:

```
C:\Users\Dell\Desktop\hbase-atelier>python import_hbase.py
Index(['gender', 'age', 'university', 'degree_level', 'degree_major',
      'academic_year', 'cgpa', 'residential_status', 'campus_discrimination',
      'sports_engagement', 'average_sleep', 'study_satisfaction',
      'academic_workload', 'academic_pressure', 'financial_concerns',
      'social_relationships', 'depression', 'anxiety', 'isolation',
      'future_insecurity', 'stress_relief_activities'],
      dtype='object')
All columns imported successfully!
```

❖ Description :

Le dataset utilisé **MentalHealthSurvey.csv** contenant des informations sur les étudiants (âge, genre, stress, anxiété, dépression, etc...).

Le script Python utilisé permet :

- ✚ la lecture du fichier CSV,
- ✚ le nettoyage des colonnes,
- ✚ l'insertion de toutes les colonnes dans HBase.

Chaque ligne du CSV est stockée comme une row dans HBase, et chaque colonne est insérée dans la column family info.

❖ Script Python utilisé pour l'importation des données dans HBase :

```
import pandas as pd
import happybase

# connexion
connection = happybase.Connection('127.0.0.1', 9098)
connection.open()

# table
table = connection.table('students')

# read CSV
df = pd.read_csv(r'C:\Users\Dell\Downloads\MentalHealthSurvey.csv')

# clean columns names
df.columns = df.columns.str.strip()

print(df.columns)

# insert data
with table.batch(batch_size=5) as batch:
    for i, row in df.iterrows():
        row_key = str(i)
        data = {}

        # clean column names
        clean_col = col.replace(" ", "_").lower()

        data[f'info:{clean_col}'.encode()] = value.encode()

        batch.put(row_key.encode(), data)

print("All columns imported successfully!")
```

❖ Description:

Le script Python utilisé dans ce projet permet d'importer les données du fichier CSV vers la base de données HBase en utilisant la bibliothèque HappyBase. Au début, les bibliothèques pandas et happybase sont importées afin de manipuler les données et établir une connexion avec HBase. Ensuite, une connexion est créée avec le serveur HBase via l'adresse locale 127.0.0.1 et le port 9098.

Le programme accède ensuite à la table students où seront stockées les données des étudiants. Le fichier MentalHealthSurvey.csv est lu grâce à la fonction read_csv() puis chargé dans un DataFrame. Après cela, les noms des colonnes sont nettoyés avec strip() afin de supprimer les espaces inutiles.

Le script utilise une insertion par lots (batch insert) avec une taille de 5 lignes pour améliorer les performances. Une boucle parcourt toutes les lignes du fichier CSV, chaque ligne représentant un étudiant. Une clé unique (row_key) est générée pour chaque enregistrement.

Ensuite, un dictionnaire data est créé pour stocker les colonnes et leurs valeurs correspondantes. Les noms des colonnes sont nettoyés en remplaçant les espaces par des underscores _ et en les convertissant en minuscules afin d'assurer une meilleure organisation des données dans HBase.

Chaque donnée est ensuite ajoutée à la famille de colonnes info avant d'être insérée dans la table students grâce à la méthode batch.put(). Enfin, le programme affiche un message confirmant la réussite de l'importation des données dans HBase.

➤ Filtrage des données des étudiants selon le niveau de depression :

```
hbase(main):005:0> scan 'students', {FILTER => "SingleColumnValueFilter('info', 'depression', =, 'binary:5')"}
ROW
13      column=info:academic_pressure, timestamp=1780736254516, value=4
13      column=info:academic_workload, timestamp=1780736254516, value=3
13      column=info:academic_year, timestamp=1780736254516, value=1st year
13      column=info:age, timestamp=1780736254516, value=19
13      column=info:anxiety, timestamp=1780736254516, value=4
13      column=info:average_sleep, timestamp=1780736254516, value=4-6 hrs
13      column=info:campus_discrimination, timestamp=1780736254516, value=No
13      column=info:cgpa, timestamp=1780736254516, value=3.0-3.5
13      column=info:degree_level, timestamp=1780736254516, value=Undergraduate
13      column=info:degree_major, timestamp=1780736254516, value=Data Science
13      column=info:depression, timestamp=1780736254516, value=5
13      column=info:financial_concerns, timestamp=1780736254516, value=5
13      column=info:future_insecurity, timestamp=1780736254516, value=1
13      column=info:gender, timestamp=1780736254516, value=Male
13      column=info:isolation, timestamp=1780736254516, value=5
13      column=info:residential_status, timestamp=1780736254516, value=Off-Campus
13      column=info:social_relationships, timestamp=1780736254516, value=3
13      column=info:sports_engagement, timestamp=1780736254516, value=No Sports
```

➤ Filtrage des étudiants selon le niveau de pression académique dans HBase :

```
hbase(main):007:0> scan 'students', {FILTER => "SingleColumnValueFilter('info', 'academic_pressure', =, 'binary:5')"}
ROW COLUMN+CELL
0 column=info:academic_pressure, timestamp=1780736254374, value=5
0 column=info:academic_workload, timestamp=1780736254374, value=4
0 column=info:academic_year, timestamp=1780736254374, value=2nd year
0 column=info:age, timestamp=1780736254374, value=20
0 column=info:anxiety, timestamp=1780736254374, value=1
0 column=info:average_sleep, timestamp=1780736254374, value=4-6 hrs
0 column=info:campus_discrimination, timestamp=1780736254374, value=No
0 column=info:cgpa, timestamp=1780736254374, value=3.0-3.5
0 column=info:degree_level, timestamp=1780736254374, value=Undergraduate
0 column=info:degree_major, timestamp=1780736254374, value=Data Science
0 column=info:depression, timestamp=1780736254374, value=2
0 column=info:financial_concerns, timestamp=1780736254374, value=4
0 column=info:future_insecurity, timestamp=1780736254374, value=2
```

4.MapReduce :

MapReduce a été utilisé pour effectuer des traitements distribués sur les données du dataset. Dans notre cas, il permet de transformer et d'agréger les informations contenues dans le fichier CSV, comme par exemple le calcul de statistiques sur les niveaux de stress ou les réponses des étudiants.

- ✚ **Le mécanisme Map** : Découpe chaque ligne du fichier CSV et associe chaque valeur ou ligne à une clé avec un compteur initial égal à 1.
- ✚ **Le mécanisme Reduce** : Regroupe toutes les clés identiques, fait la somme de leurs occurrences et écrit le résultat final dans un fichier texte structuré séparé par des tabulations.

❖ Les etapes de traitement :

```
Microsoft Windows [version 10.0.19045.6466]
(c) Microsoft Corporation. Tous droits réservés.

C:\Users\User>cd C:\Users\User\OneDrive\Bureau\ProjetBigData

C:\Users\User\OneDrive\Bureau\ProjetBigData>docker cp .\MentalHealthSurvey.csv namenode:/tmp/
successfully copied 15.4kB to namenode:/tmp/

C:\Users\User\OneDrive\Bureau\ProjetBigData>docker exec -it namenode hadoop jar /opt/hadoop-3.2.1/share/hadoop/mapreduce/hadoop-mapreduce-examples-3.2.1.jar wordcount file:///tmp/MentalHealthSurvey.csv file:///t
p/survey-result
0026-06-06 13:33:30,756 INFO impl.MetricsConfig: Loaded properties from hadoop-metrics2.properties
0026-06-06 13:33:30,876 INFO impl.MetricsSystemImpl: Scheduled Metric snapshot period at 10 second(s).
0026-06-06 13:33:30,876 INFO impl.MetricsSystemImpl: JobTracker metrics system started
org.apache.hadoop.mapred.FileAlreadyExistsException: Output directory file:///tmp/survey-result already exists
    at org.apache.hadoop.mapreduce.lib.output.FileOutputFormat.checkOutputSpecs(FileOutputFormat.java:164)
    at org.apache.hadoop.mapreduce.JobSubmitter.checkSpecs(JobSubmitter.java:277)
    at org.apache.hadoop.mapreduce.JobSubmitter.submitJobInternal(JobSubmitter.java:143)
    at org.apache.hadoop.mapreduce.Job$11.run(Job.java:1570)
    at org.apache.hadoop.mapreduce.Job$11.run(Job.java:1567)
    at java.security.AccessController.doPrivileged(Native Method)
    at javax.security.auth.Subject.doAs(Subject.java:422)
    at org.apache.hadoop.security.UserGroupInformation.doAs(UserGroupInformation.java:1730)
    at org.apache.hadoop.mapreduce.Job.submit(Job.java:1567)
    at org.apache.hadoop.mapreduce.Job.waitForCompletion(Job.java:1588)
    at org.apache.hadoop.examples.WordCount.main(WordCount.java:87)
    at sun.reflect.NativeMethodAccessorImpl.invoke0(Native Method)
    at sun.reflect.NativeMethodAccessorImpl.invoke(NativeMethodAccessorImpl.java:62)
    at sun.reflect.DelegatingMethodAccessorImpl.invoke(DelegatingMethodAccessorImpl.java:43)
    at java.lang.reflect.Method.invoke(Method.java:498)
    at org.apache.hadoop.util.ProgramDriver$ProgramDescription.invoke(ProgramDriver.java:71)
    at org.apache.hadoop.util.ProgramDriver.run(ProgramDriver.java:144)
    at org.apache.hadoop.examples.ExampleDriver.main(ExampleDriver.java:74)
    at sun.reflect.NativeMethodAccessorImpl.invoke0(Native Method)
    at sun.reflect.NativeMethodAccessorImpl.invoke(NativeMethodAccessorImpl.java:62)
    at sun.reflect.DelegatingMethodAccessorImpl.invoke(DelegatingMethodAccessorImpl.java:43)
    at java.lang.reflect.Method.invoke(Method.java:498)
    at org.apache.hadoop.util.RunJar.run(RunJar.java:323)
    at org.apache.hadoop.util.RunJar.main(RunJar.java:236)

C:\Users\User\OneDrive\Bureau\ProjetBigData>docker exec -it namenode bash -c "echo '=== LES 20 PREMIERS MOTS ===' && head -n 20 /tmp/survey-result/part-r-00000 && echo '' && echo '=== MOTS CLÉS DU SONDAGE ===' &
grep -E -i 'mental|health|yes|no|'age' /tmp/survey-result/part-r-00000"
=== LES 20 PREMIERS MOTS ===
academic_pressure,financial_concerns,social_relationships,depression,anxiety,isolation,future_insecurity,stress_relief_activities      1
activities      15
activities"     10
activities,     40
connections     3
connections"    7
connections,    23
creative        6
```

➤ Étape 1 : Copier le fichier de données dans le conteneur Hadoop

Avec : “ **docker cp .MentalHealthSurvey.csv namenode:/tmp/** “

Cette commande transfère ton fichier MentalHealthSurvey.csv depuis le Bureau vers le dossier temporaire interne de la machine Hadoop (namenode).

➤ **Étape 2 : Lancer le calcul MapReduce WordCount**

Avec : **“docker exec -it namenode hadoop jar /opt/hadoop-3.2.1/share/hadoop/mapreduce/hadoop-mapreduce-examples-3.2.1.jar wordcount file:///tmp/MentalHealthSurvey.csv <file:///tmp/survey-result>”**

Cette commande exécute le traitement Big Data (Algorithme WordCount) en mode local à l'intérieur du conteneur pour compter le nombre d'occurrences de chaque mot.

➤ **Étape3 : Afficher le résultat final**

Avec : **“docker exec -it namenode bash -c "echo '=== LES 20 PREMIERS MOTS ===' && head -n 20 /tmp/survey-result/part-r-00000 && echo " && echo '=== MOTS CLÉS DU SONDAGE ===' && grep -E -i 'mental|health|yes|no|^age' /tmp/survey-result/part-r-00000" “**

- *Cette commande vas lire le fichier de sortie (part-r-00000) généré par le Reducer et filtrer proprement les mots clés les plus importants de ton sondage (comme Mental, Health, Yes, No, Age) pour les afficher sous forme de tableau à l'écran.*

```

reative 6
ngineering,4th 3
ntertainment 9
ntertainment" 14
ntertainment, 14
emale,17,PU,Undergraduate,Computer 2
emale,18,PU,Undergraduate,Data 1
emale,19,PU,Undergraduate,Computer 1
emale,19,PU,Undergraduate,Data 9
emale,19,UET,Undergraduate,Computer 2
emale,20,PU,Undergraduate,Data 3
emale,20,UET,Undergraduate,Computer 3
emale,21,PU,Undergraduate,Information 2

```

=== MOTS CLÉS DU SONDAGE ===

```

echnology,1st 3
echnology,4th 6
rs,5,3,5,5,1,4,4,2,Nothing 1
ear,0.0-0.0,Off-Campus,No,1-3 1
ear,0.0-0.0,Off-Campus,No,7+ 3
ear,0.0-0.0,On-Campus,No,No 1
ear,1.5-2.0,Off-Campus,Yes,7+ 1
ear,1.5-2.0,On-Campus,No,No 1
ear,2.0-2.5,Off-Campus,No,1-3 1
ear,2.0-2.5,Off-Campus,No,No 1
ear,2.0-2.5,On-Campus,No,1-3 1
ear,2.0-2.5,On-Campus,No,No 1
ear,2.5-3.0,Off-Campus,No,1-3 3
ear,2.5-3.0,Off-Campus,No,4-6 2
ear,2.5-3.0,Off-Campus,No,No 7
ear,2.5-3.0,Off-Campus,Yes,1-3 3
ear,2.5-3.0,Off-Campus,Yes,4-6 1
ear,2.5-3.0,Off-Campus,Yes,No 1
ear,2.5-3.0,On-Campus,No,7+ 1
ear,2.5-3.0,On-Campus,No,No 2
ear,2.5-3.0,On-Campus,Yes,1-3 1
ear,2.5-3.0,On-Campus,Yes,4-6 1
ear,3.0-3.5,Off-Campus,No,1-3 5
ear,3.0-3.5,Off-Campus,No,4-6 2
ear,3.0-3.5,Off-Campus,No,7+ 2
ear,3.0-3.5,Off-Campus,No,No 8
ear,3.0-3.5,Off-Campus,Yes,No 5
ear,3.0-3.5,On-Campus,No,No 5
ear,3.5-4.0,Off-Campus,No,1-3 3
ear,3.5-4.0,Off-Campus,No,4-6 2
ear,3.5-4.0,Off-Campus,No,7+ 3
ear,3.5-4.0,Off-Campus,No,No 2
ear,3.5-4.0,Off-Campus,Yes,1-3 4
ear,3.5-4.0,Off-Campus,Yes,4-6 2
ear,3.5-4.0,Off-Campus,Yes,No 3

```



1	hrs,4,3,4,4,4,3,4,4,2,"Sports	1
2	hrs,4,3,5,3,3,4,4,4,4,Outdoor	1
3	hrs,4,4,3,1,1,3,3,5,2,Online	1
4	hrs,4,4,3,3,2,4,4,3,2,"Religious	1
5	hrs,4,4,3,5,1,3,3,4,1,"Religious	1
6	hrs,4,4,4,2,4,2,2,2,3,Outdoor	1
7	hrs,4,4,4,3,4,2,2,1,3,Sports	1
8	hrs,4,4,4,3,4,2,2,2,4,"Religious	1
9	hrs,4,4,4,4,1,1,1,1,4,"Religious	1
10	hrs,4,4,4,4,5,3,3,1,3,Sports	1
11	hrs,4,4,4,5,2,3,2,4,2,Sleep	1
12	hrs,4,4,4,5,2,5,4,4,5,"Social	1
13	hrs,4,4,4,5,3,4,4,5,2,Religious	1
14	hrs,4,4,5,4,3,4,4,4,5,Religious	1
15	hrs,4,5,4,4,4,2,3,1,2,"Religious	1
16	hrs,4,5,5,1,5,3,4,1,1,"Religious	1
17	hrs,4,5,5,2,2,4,4,5,5,"Religious	1
18	hrs,4,5,5,3,3,2,2,3,3,"Religious	1
19	hrs,4,5,5,3,3,5,5,5,5,"Religious	1
20	hrs,4,5,5,5,1,5,5,5,3,Sleep	1
21	hrs,4,5,5,5,4,3,4,2,3,"Social	1
22	hrs,5,2,2,1,3,1,1,1,1,"Religious	1
23	hrs,5,3,1,1,3,1,2,2,1,Sleep	1
24	hrs,5,3,1,5,3,1,1,2,1,Religious	1
25	hrs,5,3,2,2,4,1,2,1,1,Religious	1
26	hrs,5,3,3,2,4,1,1,2,2,"Religious	1
27	hrs,5,3,3,3,4,2,2,2,4,"Social	1
28	hrs,5,3,3,4,3,1,1,1,3,"Religious	1
29	hrs,5,3,4,3,2,4,4,4,5,"Religious	1
30	hrs,5,3,4,3,5,3,3,3,1,"Religious	1
31	hrs,5,3,5,3,3,2,2,3,1,Religious	1
32	hrs,5,3,5,5,1,4,4,4,2,Nothing	1

IV. Interprétation Globale et Analyse Critique des Résultats Visuels

L'analyse croisée des différents composants du tableau de bord décisionnel (Enterprise Intelligence Platform) met en évidence la cohérence de l'architecture mise en œuvre, intégrant les couches d'ingestion HDFS, le moteur de traitement distribué Apache Spark et l'interface de visualisation Streamlit. Les résultats obtenus à travers les différents modules permettent d'évaluer simultanément les dimensions statistiques, analytiques et décisionnelles du système proposé.

1 .Analyse Statistique des Données et Distribution des Classes

Le module Data Pipeline Ingestion affiche un flux instantané de 87 observations, représentant un échantillon opérationnel extrait du cluster Hadoop. L'indice moyen de pression académique atteint une valeur de 3,78/5, ce qui suggère un niveau de contrainte relativement élevé au sein de la population étudiée analysée.

Cette observation est renforcée par l'étude de la distribution de la variable cible (Target Variable Density Distribution). Les différentes classes présentent une répartition relativement hétérogène : Classe 1 (23 %), Classe 2 (16,1 %), Classe 3 (24,1 %), Classe 4 (21,8 %) et Classe 5 (14,9 %). Cette variabilité justifie l'utilisation d'un critère de division fondé sur l'entropie lors de la construction des arbres de décision, afin de maximiser le gain d'information à chaque étape du processus d'apprentissage

2 .Valuation du Modèle et Analyse d'Explicabilité (XAI)

Le module Advanced ML Diagnostics fournit une matrice de confusion permettant d'évaluer les performances du modèle de classification. La concentration des observations sur la diagonale principale indique une capacité satisfaisante du modèle à identifier correctement plusieurs classes. Les écarts observés hors diagonale traduisent les erreurs de classification attendues dans le cadre d'un apprentissage supervisé réalisé sur un échantillon de taille limitée. L'analyse d'explicabilité (XAI Insights) met en évidence l'importance relative des variables utilisées par le modèle. Les résultats montrent que l'Âge constitue la variable la plus influente, avec un score supérieur à 0,20, suivi de la Pression Académique et de la Charge de Travail, dont les contributions se situent autour de 0,18. À l'inverse, la variable Genre présente une importance plus faible. Ces observations suggèrent que les facteurs liés au parcours académique et à l'environnement de travail étudiant jouent un rôle plus déterminant dans la prédiction du niveau de stress que les caractéristiques démographiques considérées.

3 .Analyse de la Projection 3D et Inférence en Temps Réel

Le module Real-Time AI Simulator illustre le comportement du modèle lors d'une inférence en temps réel. Pour le profil étudié (22 ans, genre masculin, filière Data Science, pression académique de 4/5, charge de travail de 3/5 et satisfaction de 2/5), le système prédit un statut stable. Ce résultat montre que la décision finale repose sur une combinaison de plusieurs variables plutôt que sur un unique indicateur pris isolément. Cette logique est également observable dans la visualisation tridimensionnelle (Interactive 3D Cube Analytics). La projection des données selon les dimensions Âge, Pression Académique et Satisfaction fait apparaître des regroupements naturels d'observations. Les zones caractérisées par une forte pression académique et un faible niveau de satisfaction tendent à être associées aux niveaux les plus élevés de détresse psychologique, ce qui confirme la cohérence globale des tendances identifiées par le modèle.

4 .Évaluation du Pipeline Spark et Perspectives Institutionnelles

Le module Smart Prescriptive Engine valide l'intégration du framework Apache Spark au sein du pipeline d'analyse. Le traitement de 69 étudiants correspond à la portion d'entraînement représentant environ 80 % de l'échantillon total. Le modèle atteint une précision globale de 40,14 %. Bien que cette performance puisse paraître modérée, elle doit être interprétée en tenant compte du caractère multiclassés du problème (cinq niveaux de classification) ainsi que de la taille relativement réduite du jeu de données disponible. L'examen des résultats générés par le pipeline Spark montre néanmoins la capacité du système à produire des prédictions cohérentes et exploitables dans un contexte réel. Enfin, l'intégration d'un mécanisme d'alerte ciblant les étudiants des filières Computer Science et Data Science démontre l'intérêt opérationnel de la plateforme. Grâce aux capacités de traitement distribuées de Spark MLlib, le système ne se limite pas à l'analyse descriptive des données, mais fournit également des éléments d'aide à la décision susceptibles de soutenir les actions préventives de l'établissement. Les recommandations proposées, notamment le renforcement des dispositifs d'accompagnement psychologique et l'adaptation de l'organisation des évaluations académiques, illustrent la valeur ajoutée potentielle de cette solution dans un contexte universitaire

V. Conclusion et Recommandations

La réalisation de ce projet nous a permis de mettre en pratique les différents concepts étudiés dans le module Big Data à travers un cas concret portant sur la santé mentale des étudiants. En utilisant les outils de l'écosystème Hadoop tels que HDFS, Hive, HBase, MapReduce et Apache Spark, nous avons pu suivre toutes les étapes d'un processus Big Data, depuis le stockage des données jusqu'à leur analyse et leur visualisation.

L'étude du dataset a montré que plusieurs facteurs, notamment la pression académique, la charge de travail, la satisfaction des études et les inquiétudes concernant l'avenir, peuvent avoir un impact important sur le bien-être psychologique des étudiants. Les résultats obtenus ont également démontré que l'analyse de données peut constituer un outil efficace pour mieux comprendre ces problématiques et identifier les étudiants susceptibles de rencontrer des difficultés.

Au-delà des aspects techniques, ce projet nous a permis de prendre conscience de l'importance de la santé mentale dans le milieu universitaire. Il montre qu'une exploitation intelligente des données peut aider les établissements à mettre en place des actions préventives et un meilleur accompagnement des étudiants.

Pour aller plus loin, il serait intéressant de travailler sur un volume de données plus important et d'intégrer davantage de variables afin d'améliorer la qualité des analyses. L'utilisation de modèles d'intelligence artificielle plus performants pourrait également permettre d'obtenir des prédictions plus précises et d'apporter une aide encore plus efficace à la prise de décision.

En conclusion, ce projet a été une expérience enrichissante aussi bien sur le plan technique que sur le plan analytique. Il nous a permis de consolider nos compétences en Big Data tout en explorant une problématique actuelle et importante pour la communauté étudiante.